TeAAL Pyramid of Concerns & FuseMax 해설

MIT 6.5930 L01-28 ~ L01-34

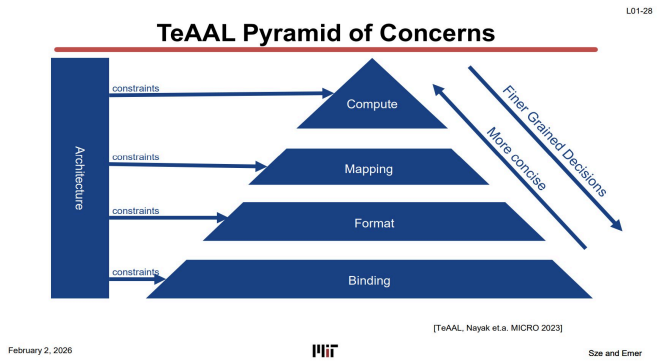

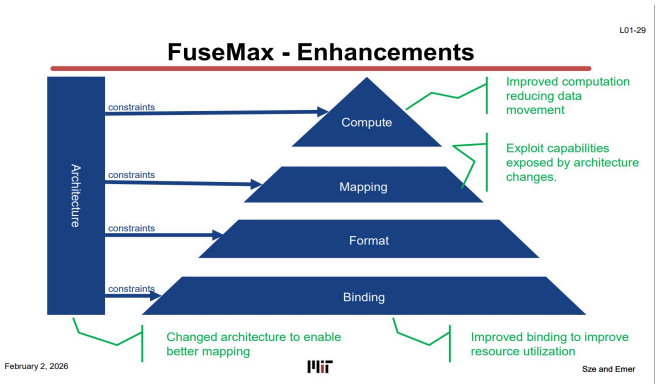

1. TeAAL Pyramid (L01-28)

Accelerator 설계를 4개 계층으로 분해하는 프레임워크. Architecture가 각 계층에 constraint를 걸고, 위로 갈수록 결정이 세밀해진다.

계층	의미	수업 연결
Compute (꼭대기)	어떤 연산을 하느냐 (MatMul, Attention)	Lab 1: Einsum
Mapping	연산을 HW에 어떻게 배치 (tiling, dataflow)	Lab 2, 3
Format	데이터 저장 형태 (dense, CSR 등)	Lab 4: Sparsity
Binding (바닥)	물리적 HW에 할당 (PE, Buffer)	Lab 2, 3

2. FuseMax (L01-29~34) — 피라미드 각 계층을 개선한 사례

Transformer Attention 가속 설계. 각 계층에서 하나씩 개선하여 PE utilization을 0% -> 90%로 끌어올림.

단계	계층	개선 내용	결과
Cascade	Compute	MatMul+Softmax fuse, data movement 제거	util 소폭 상승
Arch 변경	Arch->Mapping	새로운 mapping을 가능하게 아키텍처 수정	util 유의미 상승
Binding	Binding	PE에 효율적 할당, 자원 활용 극대화	util ~90%

3. FlashAttention 프로젝트 연결

계층	FlashAttention 대응
Compute	Online Softmax로 attention matrix materialize 제거
Mapping	Q,K,V를 SRAM 크기 블록으로 tiling, SM 내부 연산 완료
Format	FP16/BF16 정밀도 선택, 향후 FP8
Binding	각 tile을 SM/warp에 할당 (CUDA grid/block 설계)

> Takeaway: Accelerator 성능은 단일 요소가 아니라 피라미드의 모든 계층(Compute + Mapping + Format + Binding)이 함께 최적화되어야 나온다. 이 프레임워크가 수업 전체를 관통한다.